

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика»

Лабораторная работа №1
по курсу «Добыча корпуса документов»

Выполнил: *Белушкин Антон Романович*

Группа: *М8О-407Б-22*

Преподаватель: *Кухтичев Антон Алексеевич*

Москва, 2025

1. Источники данных

Для лабораторной работы был выбран корпус текстов из двух источников:

1. Project Gutenberg

- Сайт: <https://www.gutenberg.org>
- Содержит тексты классической литературы в формате Plain Text UTF-8.
- Примеры документов:
 - The Adventures of Sherlock Holmes
 - Pride and Prejudice

2. Standard Ebooks

- Сайт: <https://standardebooks.org>
- Содержит тексты классической литературы, аккуратно отформатированные для электронных книг.
- Примеры документов:
 - The Red Thumbmark
 - The Call of the Wild
- Для анализа использовались тексты со страниц, заканчивающихся на text/single-page.

2. Характеристика корпусов

Корпус	Формат документов	Доп. мета-информация	Разметка текста
Gutenberg	Plain Text UTF-8	Название, автор, год публикации	Заголовки, шапка и футер
Standard Ebooks	HTML → извлечённый TXT	Название, автор, год публикации	HTML-разметка, абзацы

Комментарии:

- Gutenberg содержит длинные художественные тексты.
- Standard Ebooks предоставляет тексты классической литературы, аккуратно структурированные и очищенные.

3. Выделение текста

Gutenberg

- Удалены первые и последние 50 строк (стандартные шапка и футер Project Gutenberg).

Standard Ebooks

- Из HTML извлечены только страницы text/single-page.
- Извлечены:
 - заголовки и подзаголовки
 - текстовые абзацы
- Игнорированы:
 - навигация по сайту
 - ссылки на внешние ресурсы
 - служебные блоки и изображения

4. Поиск по корпусу

Gutenberg

- Встроенный поиск: <https://www.gutenberg.org/ebooks/search>
- Примеры запросов: "Sherlock Holmes", "Alice in Wonderland"
- Недостаток: полнотекстовый поиск недоступен.

Standard Ebooks

- Встроенный поиск: <https://standardebooks.org/ebooks>
- Примеры запросов: "The Red Thumbmark", "The Call of the Wild"
- Недостатки:
 - поиск ограничен по метаданным и заголовкам
 - возможны промежуточные страницы без текста single-page

5. Статистическая информация о корпусах

Корпус	Кол-во документов	Размер сырых файлов (байт)	Размер текста (байт)	Средний размер (сырой)	Средний текстовый размер
Gutenberg	20	3 200 000	2 900 000	160 000	145 000
Standard Ebooks	50	1 500 000	1 200 000	30 000	24 000

Примечания:

- В Standard Ebooks «сырой» размер включает HTML-разметку.
- Размер текста учитывает только очищенный контент со страниц text/single-page.
- Разница в длине документов объясняется природой контента: книги разного объема.

6. Выводы

1. Оба корпуса подходят для анализа, так как представляют тексты художественной литературы разной природы и разной обработки.
2. Gutenberg содержит большие классические произведения, Standard Ebooks — аккуратно отформатированные тексты классики, готовые для электронных книг.
3. Поиск в Gutenberg и Standard Ebooks работает по разным принципам, что влияет на релевантность.
4. Основные недостатки:
 - Gutenberg: отсутствие полнотекстового поиска.
 - Standard Ebooks: необходимо фильтровать только страницы text/single-page для анализа.