

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика»

Лабораторная работа №1
по курсу «Поисковый робот»

Выполнил: *Белушкин Антон Романович*

Группа: *М8О-407Б-22*

Преподаватель: *Кухтичев Антон Алексеевич*

Москва, 2025

1. Цель работы

Разработать веб-краулер на языке Python с использованием асинхронного программирования (asyncio), который способен:

- загружать тексты книг с сайтов Project Gutenberg и Standard Ebooks;
- хранить данные в MongoDB;
- обеспечивать контроль повторной проверки документов и уникальность контента;
- эффективно использовать параллельные запросы с ограничением конкуренции;
- расширять очередь загрузки ссылками, найденными на страницах.

2. Постановка задачи

Необходимо реализовать систему, которая:

1. Загружает тексты книг по заранее определенному диапазону идентификаторов (Gutenberg) или по стартовому URL (Standard Ebooks).
2. Хранит тексты в MongoDB с уникальным хэшированием содержимого (SHA-256).
3. Поддерживает асинхронную обработку множества заданий с использованием семафоров для ограничения числа одновременных запросов.
4. Обеспечивает возможность повторной проверки старых документов через заданный интервал (recheck_interval).
5. Позволяет добавлять новые ссылки из HTML-контента в очередь для дальнейшей обработки.

3. Используемые технологии

- Язык программирования: Python 3.11+
- Асинхронные библиотеки: asyncio, aiohttp
- База данных: MongoDB с асинхронным драйвером motor
- Формат конфигурации: YAML
- Регулярные выражения: re для фильтрации ссылок
- Хэширование контента: hashlib.sha256
- Логирование: logging

4. Структура кода

4.1 Основные компоненты

- **MongoCrawler** – основной класс краулера, инкапсулирующий логику работы с базой и HTTP-запросами.
- **Методы класса:**
 - `init()` – инициализация HTTP-сессии и индексов MongoDB.
 - `seed_gutenberg_range()` – заполнение очереди Gutenberg по ID книг.
 - `seed_standardebooks()` – добавление стартового URL Standard Ebooks.
 - `crawl_gutenberg_worker()` и `crawl_standardebooks_worker()` – асинхронные рабочие процессы для загрузки страниц.
 - `fetch_and_store()` – загрузка страницы, сохранение текста и хэша.
 - `enqueue_links_from_body()` – извлечение ссылок из HTML и добавление в очередь.

- `recheck_scheduler()` – планировщик повторной проверки старых документов.
- `run()` – запуск всех рабочих задач и планировщика.

4.2 Механизм семафоров

Для ограничения числа одновременных HTTP-запросов используется `asyncio.Semaphore`. Это позволяет контролировать нагрузку на сайты и локальные ресурсы.

```
async with self.sem:
    async with aiohttp.ClientSession() as session:
        async with session.get(url) as resp:
            ...
```

4.3 Хэширование и проверка изменений

Каждый загруженный документ хэшируется с помощью SHA-256. Если хэш отличается от существующего в базе, документ обновляется.

```
content_hash = sha256_hex(body)

if not doc or doc.get('content_hash') != content_hash:
    await docs_coll.update_one({'url': url}, {'$set': payload}, upsert=True)
```

4.4 Очереди и повторная проверка

- Все URL хранятся в коллекциях очередей (`queue_collection`).
- Если документ устарел (`last_checked < cutoff`), его URL помещается обратно в очередь для повторной проверки.

5. Пример работы

1. Краулер инициализируется с конфигурационным файлом `config.yaml`.
2. Запускаются рабочие задачи для Gutenberg и Standard Ebooks.
3. Тексты загружаются и сохраняются в MongoDB.

4. Новые ссылки автоматически добавляются в очередь для последующего обхода.
5. Старые документы периодически проверяются на изменения.

6. Выводы

В ходе лабораторной работы был разработан эффективный асинхронный веб-краулер для загрузки текстов книг с популярных онлайн-библиотек.

- Реализована параллельная обработка с ограничением числа одновременных запросов.
- Использован хэш контента для отслеживания изменений.
- Поддерживаются автоматическое добавление ссылок и повторная проверка документов.
- Полученные данные сохраняются в MongoDB с индексами для быстрого поиска и уникальности.

Данный краулер может быть расширен для работы с другими источниками, добавления анализа текста и интеграции с веб-платформой по обработке литературы.